

Exploitation des formulaires DPI personnalisés

Extraire, standardiser et documenter des données cliniques hétérogènes sans perdre leur sens, leur provenance ni leurs états d'absence.

Contexte

Un même DPI équipe plusieurs centaines d'établissements. Chacun configure ses formulaires, libellés, listes de valeurs, unités, conditions d'affichage, groupes répétés et documents. Une même information clinique peut donc exister sous forme de colonne SQL, EAV, QuestionnaireResponse FHIR, CDA, JSON/XML, texte natif, PDF ou scan.


Thèse. La structure vient du moteur de formulaires, le sens vient de mappings revus, et la publication reste déterministe. Un élément inconnu est conservé et mis en quarantaine ; il n'est jamais deviné.

Échelle et contraintes

100 Godonnées
structurées / site**800 Go**données non
structurées / site**100 M+**réponses traitées
par partitions

- Reprises historiques et rafraîchissements incrémentaux.
- Versions locales et cycles de correction, annulation ou suppression.
- IA entraînée et exécutée en France ; aucun appel clinique externe.
- Résultats de recherche traçables, signés et reproductibles.

**Lire la définition avant les
réponses****Séparer brut, canonique et
OMOP****Lier chaque fait à une
preuve****Publier seulement après
contrôles****Exposer couverture et
limites**

**Monolithe modulaire.**

API, worker, CLI et OCR sont des processus séparés qui partagent les mêmes services.

Durabilité native.

PostgreSQL porte les tâches, baux, heartbeats, retries, outbox et clés d'idempotence.

Artefacts contrôlés.

Mappings et releases sont immuables, adressés par SHA-256 et vérifiables par signature Ed25519.

Orchestration sobre.

Airflow est optionnel et planifie les services ; aucune logique clinique ne vit dans les DAG.

Sources, modèle canonique et stockage


Familles de sources

Source	Traitement
Relationnel / EAV	Extraction SQL, schéma et parsing typé
Formulaires dynamiques	Hiérarchie, conditions, calculs et répétitions
FHIR R4 / CDA	Adaptateurs conformes, extensions ambiguës refusées
JSON / XML / HTML	Parsing sécurisé et références source exactes
PDF / scans	Texte natif d'abord ; OCR local si pertinent
Cycle de vie	Brouillon, signé, corrigé, annulé, supprimé

États sémantiques conservés

PRESENT EXPLICITLY_ABSENT UNKNOWN NOT_RECORDED NOT_APPLICABLE
 NOT_DISPLAYED_BY_FORM_LOGIC INVALID VOIDED SUPERSEDED DELETED

Une réponse négative, un champ vide et un champ masqué ne sont jamais réduits au même null.




Deux empreintes, deux usages

- **Définition complète** : identité, métadonnées et représentation source.
- **Compatibilité** : chemins, libellés, types, valeurs, unités, répétitions, conditions, calculs et ordre sémantique.

Couches de stockage

Brut	Objets immuables, manifestes et checksums
Canonique	Parquet borné, source sémantique sans perte
Contrôle	PostgreSQL : mappings, jobs, audit et catalogue
Recherche	OMOP 5.4 + tables distinctes de release et lignage

Mapping et traitement déterministe



Ordre de résolution

- 1 Override exact propre à l'établissement
- 2 Empreinte exacte liée à la release
- 3 Famille de formulaire et chemin exact
- 4 Aucun mapping : quarantaine explicite

Ni similarité floue, ni embedding, ni réponse de LLM ne décide au runtime.

Contrat d'un mapping publié

Identité source, domaine et concept cible, version du vocabulaire, valeurs locales, conversions d'unités bornées, règles d'absence/négation, comportement conditionnel et répété, reviewers maker/checker, vecteurs de test, checksum et signature détachée.

Le langage de transformation est déclaratif et limité à une liste blanche. Aucun code fourni par un utilisateur n'est évalué.

Correction et rejeu. Une règle corrigée crée une nouvelle release de mapping, puis une nouvelle release de recherche. Les sorties antérieures ne sont ni réécrites ni supprimées.

Données non structurées, OCR et ML



Principe de sobriété. Inventorier et dédupliquer avant d'extraire. Traiter uniquement les classes documentaires et périodes nécessaires aux variables de recherche approuvées.

Texte : « Allergie à la pénicilline avec urticaire. »

```
substance : Penicillin
assertion : PRESENT
réaction : Urticaria
méthode : CDA_RULES_OR_NLP
preuve : document_482 / p.2 / 144-189
release : clinical_text_2026_04
```

Choisir le modèle le plus simple qui réponde au besoin

Cas d'usage	Méthode privilégiée
Découverte de schéma	Métadonnées et parsing déterministe
Valeurs connues / unités	Dictionnaires exacts et conversions UCUM bornées
Scan image	PaddleOCR auto-hébergé, CPU puis GPU si mesuré
Sections et tableaux	Règles, puis modèle de layout spécialisé si nécessaire
Négation / incertitude	Règles déterministes ou classifieur validé
Entités cliniques	Dictionnaires, puis NER spécialisé
Candidats de mapping	Recherche terminologique et classement lexical
Anomalies de qualité	Contrôles déterministes et suivi statistique

Contrat de preuve

Chaque candidat conserve document, page, section, texte ou coordonnées, méthode, version d'image et de modèle, confiance et statut de validation. Une faible confiance provoque l'abstention.

Un index vectoriel n'est ni le stockage documentaire ni une dépendance de publication. Un LLM éventuellement hébergé en France aide la revue mais ne publie aucun fait.

Contrôles en couches

Niveau	Contrôles
Technique	Comptages, checksums, doublons, lots absents
Structurel	Types, identifiants, hiérarchie, groupes répétés appariés
Sémantique	Mapping signé, concepts, valeurs locales, unités
Clinique	Plages plausibles, combinaisons et ordre temporel
Provenance	Source, mapping, règles, vocabulaire et modèle
OMOP	Domaine concept, clés, dates et conformité 5.4
Scientifique	Couverture, données manquantes, biais et limites

Taxonomie d'échec exploitable

UNKNOWN_FORM_VERSION UNKNOWN_MAPPING UNKNOWN_LOCAL_VALUE INVALID_UNIT
CONDITIONAL_LOGIC_CONFLICT CLINICAL_INCONSISTENCY MISSING_PROVENANCE
OMOP_CONFORMANCE_FAILURE

Réduire la charge experte

- Valider une version de formulaire, pas chaque ligne patient.
- Réutiliser les empreintes exactes et revoir seulement les changements.
- Prioriser par risque clinique, volume et nouveauté.
- Présenter candidats, échantillons et tests de non-régression.
- Automatiser l'abstention et réaliser des audits fondés sur le risque.

Mesurer la représentativité

Par établissement et période : disponibilité, population éligible, complétion, couverture utilisable, états manquants, taux de quarantaine, couverture du mapping, distributions, démographie, spécialité et contexte de soins.

Pour le NLP, conserver au moins un site ou une famille de formulaire hors entraînement et tester les modèles sur des gabarits jamais vus.

OMOP, catalogue clinique et couverture

Responsabilités distinctes. Le Parquet canonique reste la source sémantique sans perte. OMOP est une projection de recherche immuable. L'appartenance à une release et le lignage vivent dans des tables dédiées, sans colonne propriétaire ajoutée aux tables OMOP.

Identité d'un fait publié

- Preuve et valeur source
- Formulaire, chemin et état canonique
- Releases mapping, règles et vocabulaire
- Résultats qualité et méthode d'extraction
- Ligne OMOP, release de recherche et métrique catalogue

Complétion = réponses enregistrées / opportunités éligibles
Couverture utilisable = réponses validées / opportunités éligibles
Prévalence = événements positifs / enregistrements utilisables

Sans dénominateur reconstituable, publier des nombres observés et non une couverture populationnelle.

Ce que le catalogue rend visible

Définition et vocabulaire, sites contributeurs, périodes, sources, méthode, statut du mapping, volumes patient/séjour, complétion, couverture, qualité, dernier rafraîchissement, limites et release OMOP.


Exemple — antécédent d'allergie

Site	Disponible	Complétion	Utilisable	Méthode	Statut
A	Oui	87 %	84 %	Formulaire	Validé
B	Oui	Non calculable	Comptages	Règles CDA	Limité
C	Non	N/A	0 %	Aucune source	Absent
D	Partiel	62 %	55 %	Structuré + NLP	Surveillé

Mode site

Si les données individuelles ne peuvent pas sortir, le même package est exécuté localement. Le site exporte uniquement un bundle agrégé signé, avec suppression des petites cellules. Identifiants patient et lignes de réponse sont interdits par schéma et par tests.

Déploiement, risques et trajectoire



Déploiement progressif

1. Découverte de deux ou trois sites représentatifs.
2. Pilote canonique et formulaires structurés.
3. Mappings, contrôles, OMOP et catalogue sur variables ciblées.
4. Extension multi-sites par réutilisation des empreintes.
5. OCR/NLP uniquement pour les variables sans source structurée.

Principes opérationnels

Une base de code, configuration par site, conteneurs, lots bornés, ingestion idempotente, recherche de tâches avec bail, rejeu contrôlé, releases immuables, sauvegarde/restauration et télémétrie corrélée.

Risques et contrôles

Dérive sémantique	Double empreinte, tests et maker/checker
Publication erronée	Abstention, quarantaine et preuves obligatoires
Biais inter-sites	Métriques par site/période et limites publiées
Exposition de données	Pseudonymisation locale, moindre privilège, chiffrement, audit
Dépendance ML	Chemin déterministe par défaut et adaptors isolés
Non-reproductibilité	Manifestes, checksums, versions et signatures

Critères initiaux. Chaque fait publié possède une preuve et un mapping released ; une version inconnue ne publie rien ; négatif et manquant restent distincts ; les corrections gardent l'historique ; les comptages se réconcilient ; les échecs sont explicites ; la couverture est visible par site et période ; aucune donnée clinique n'est envoyée à un service d'IA externe.